

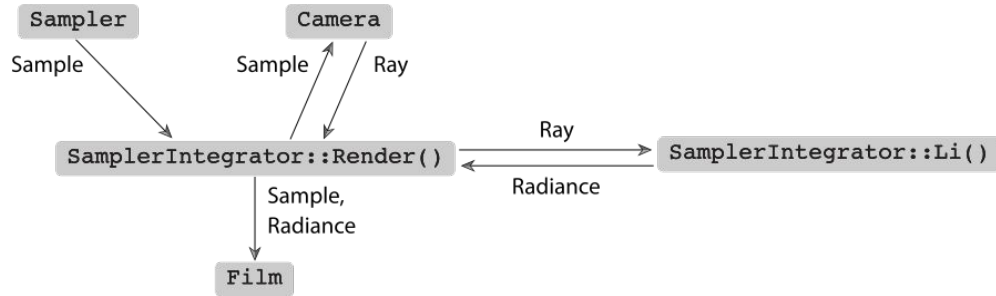
Aceleración de RayTracer

Random Parameter Filtering

- Rodrigo Gabriel Salazar Alva
- —

PBRT

RayTracing



Fórmula de Radiancia

$$I(i, j) = \int_{i-\frac{1}{2}}^{i+\frac{1}{2}} \int_{j-\frac{1}{2}}^{j+\frac{1}{2}} \cdots \int_{-1}^1 \int_{-1}^1 \int_{t_0}^{t_1} f(x, y, \cdots, u, v, t) dt dv du \cdots dy dx.$$

Parámetros

- \mathbf{x}, \mathbf{y} : posición en plano de proyección
- \mathbf{u}, \mathbf{v} : posición del lente
- \mathbf{t} : tiempo de captura
- +parámetros aleatorios

Aproximación:

- **Método:** Monte-Carlo
- **Variación:** $O(\frac{1}{n})$

Escena

RenderSystem: PBRT v2

Escena: Conference

Samples Per Pixel: 8096

Tiempo de Ejecución: 32m 33s



Profiling

Profile		
Integrator::Render()	100.00%	(2:24:28.66)
Camera::GenerateRay[Differential]()	1.35%	(0:01:57.24)
Film::AddSample()	0.42%	(0:00:36.25)
Film::MergeTile()	0.00%	(0:00:00.05)
Sampler::GetSample[12]D()	0.47%	(0:00:41.17)
Sampler::StartPixelSample()	0.56%	(0:00:48.72)
SamplerIntegrator::Li()	96.51%	(2:19:26.20)
Accelerator::Intersect()	40.84%	(0:59:00.23)
Other Shape::Intersect()	0.02%	(0:00:01.31)
Triangle::Intersect()	10.38%	(0:14:59.87)
BSDF::Sample_f()	8.55%	(0:12:20.85)
Direct lighting	39.39%	(0:56:54.27)
Accelerator::Intersect()	0.03%	(0:00:02.90)
Other Shape::Intersect()	0.01%	(0:00:00.81)
Triangle::Intersect()	0.01%	(0:00:00.48)
Accelerator::IntersectP()	11.15%	(0:16:06.23)

8096 Samples Per Pixel (PBRT v3)

Random Parameter Filtering


On Filtering the Noise from the Random Parameters in Monte Carlo Rendering

ACM Transactions on Graphics (TOG)
Vol. 31, No. 3, May 2012

Pradeep Sen

Soheil Darabi

UNM Advanced Graphics Lab



input Monte Carlo (8 samples/pixel)



after RPF (8 samples/pixel)

Propuesta de RPF

Hipótesis: Es posible mejorar la aproximación de radiancia de un pixel incorporando data de píxeles cercanos

Propuesta:

Filtro bilateral cruzado ajustado a las dependencias entre parámetros aleatorios y características de las muestras


$$w_{ij} = \exp\left[-\frac{1}{2\sigma_{\mathbf{p}}^2} \sum_{1 \leq k \leq 2} (\bar{\mathbf{p}}_{i,k} - \bar{\mathbf{p}}_{j,k})^2\right] \times \exp\left[-\frac{1}{2\sigma_{\mathbf{c}}^2} \sum_{1 \leq k \leq 3} \alpha_k (\bar{\mathbf{c}}_{i,k} - \bar{\mathbf{c}}_{j,k})^2\right] \times \exp\left[-\frac{1}{2\sigma_{\mathbf{f}}^2} \sum_{1 \leq k \leq m} \beta_k (\bar{\mathbf{f}}_{i,k} - \bar{\mathbf{f}}_{j,k})^2\right],$$

- Posición semejante = Mayor peso
- Color semejante = Mayor peso
- Características semejantes = Mayor peso

Renderizado

Creación del vector X para cada *sample* durante el renderizado:

$$X_i = \{p_{i,1}, p_{i,2}\} \parallel \{r_{i,1}, r_{i,2}, \dots\} \parallel \{f_{i,1}, f_{i,2}, \dots\} \parallel \{c_{i,1}, c_{i,2}, c_{i,3}\}$$



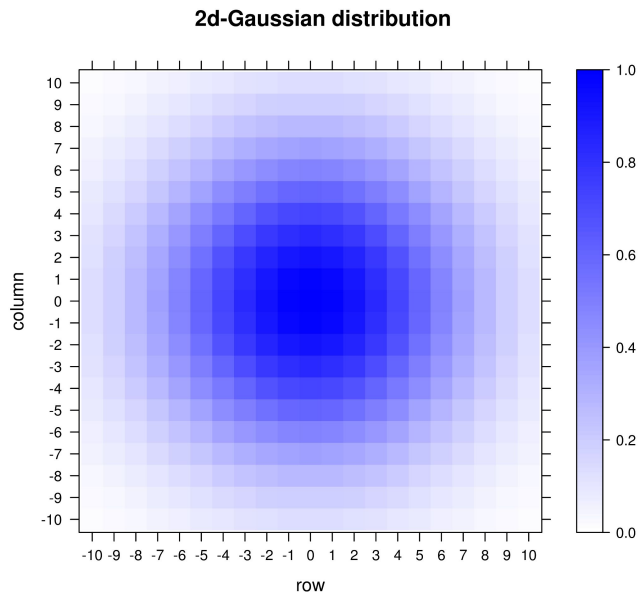
Post-procesamiento: RPF es independiente del método de integración empleado.

Construcción del *neighbourhood*

No mezclar relaciones de dependencia

- **Localidad:** Cuadrado de tamaño `box_size`
- **Relevancia:** Filtrado en base a semejanza de propiedades.

```
for scene feature  $k = 1$  to  $m$  do
  if  $|\mathbf{f}_{j,k} - \mathbf{m}_{\mathcal{P},k}^{\mathbf{f}}| > \{3|30\}\sigma_{\mathcal{P},k}^{\mathbf{f}}$  and
     $|\mathbf{f}_{j,k} - \mathbf{m}_{\mathcal{P},k}^{\mathbf{f}}| > 0.1$  or  $\sigma_{\mathcal{P},k}^{\mathbf{f}} > 0.1$  then
     $flag \leftarrow 0$ 
    break
  end if
end for
if  $flag$  equals to 1 then
   $\mathcal{N} \leftarrow \text{sample } j$ 
end if
```



Optimización: Selección aleatoria de píxeles en base a distribución gaussian

Estimación de dependencias estadísticas

Información Mutua

Cuantificación de la dependencia entre dos variables aleatorias.

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

Dependencia estadística

- 1D x 1D: $D_{y,k}^{x,l} = \mu(X_{\mathcal{N},l}; X_{\mathcal{N},k})$
- 1D x MD: $D_{y,k}^x \approx \sum_l D_{y,k}^{x,l} = \sum_l \mu(X_{\mathcal{N},l}; X_{\mathcal{N},k})$
- MD x MD: $D_y^x \approx \sum_k D_{y,k}^x$

Contribuciones fraccionales

$$W_{\mathbf{f},k}^{\mathbf{r}} = \frac{D_{\mathbf{f},k}^{\mathbf{r}}}{D_{\mathbf{f},k}^{\mathbf{r}} + D_{\mathbf{f},k}^{\mathbf{p}} + \varepsilon}$$

Contribución de los parámetros aleatorios al feature k

$$W_{\mathbf{c},k}^{\mathbf{r}} = \frac{D_{\mathbf{c},k}^{\mathbf{r}}}{D_{\mathbf{c},k}^{\mathbf{r}} + D_{\mathbf{c},k}^{\mathbf{p}} + \varepsilon}$$

Contribución de los parámetros aleatorios al canal de color k

$$W_{\mathbf{c}}^{\mathbf{f},k} = \frac{D_{\mathbf{c}}^{\mathbf{f},k}}{D_{\mathbf{c}}^{\mathbf{r}} + D_{\mathbf{c}}^{\mathbf{p}} + D_{\mathbf{c}}^{\mathbf{f},k}}$$

Contribución del feature k al color final

$$W_{\mathbf{c}}^{\mathbf{r}} = \frac{1}{3}(W_{\mathbf{c},1}^{\mathbf{r}} + W_{\mathbf{c},2}^{\mathbf{r}} + W_{\mathbf{c},3}^{\mathbf{r}})$$

Contribución de los parámetros aleatorios al color final

Factores alfa y beta

$$\alpha_k = 1 - W_{\mathbf{c},k}^{\mathbf{r}}$$

Alpha:

A medida que los parámetros aleatorios generan una menor contribución sobre el color, incrementa la importancia de su diferencia para el filtro

$$\beta_k = W_{\mathbf{c}}^{\mathbf{f},k} (1 - W_{\mathbf{f},k}^{\mathbf{r}})$$

Beta:

A medida de que un feature contribuye más a los colores y ha sido afectado menos por los parámetros aleatorios, incrementa la importancia de su diferencia para el filtro

Ajustes para múltiples pasadas del filtro

$$\alpha_k = \max(1 - 2(1 + 0.1t)W_{\mathbf{c},k}^{\mathbf{r}}, 0),$$

$$\beta_k = W_{\mathbf{c}}^{\mathbf{f},k} \cdot \max(1 - (1 + 0.1t)W_{\mathbf{f},k}^{\mathbf{r}}, 0),$$

Influencia de Vecino j sobre Pixel i

- Penaliza distancia
(posición, color y features)
- Alpha y Beta ajustan
penalización
- Cuando $i=j$ siempre es 1

$$w_{ij} = \exp\left[-\frac{1}{2\sigma_p^2} \sum_{1 \leq k \leq 2} (\bar{p}_{i,k} - \bar{p}_{j,k})^2\right] \times \\ \exp\left[-\frac{1}{2\sigma_c^2} \sum_{1 \leq k \leq 3} \alpha_k (\bar{c}_{i,k} - \bar{c}_{j,k})^2\right] \times \\ \exp\left[-\frac{1}{2\sigma_f^2} \sum_{1 \leq k \leq m} \beta_k (\bar{f}_{i,k} - \bar{f}_{j,k})^2\right],$$

Mezclar Samples

$$\mathbf{c}'_{i,k} = \frac{\sum_{j \in \mathcal{N}} w_{ij} \mathbf{c}_{j,k}}{\sum_{j \in \mathcal{N}} w_{ij}},$$

Promedio ponderado de los radiancia de los vecinos.

Experimentación

PBRTv2 (Base)

8096spp



32m 20.0s

PBRTv2 (Base)

8spp



1.8s

PBRTv2 (RPF)

8spp



3m 41.7s

Experimentación

PBRTv3 (Base)

8096spp



32m 20.0s

PBRTv2 (Base)

1024spp



3m 52.2s

PBRTv2 (RPF)

8spp



3m 41.7s

Experimentación

Base



RPF



Experimentación

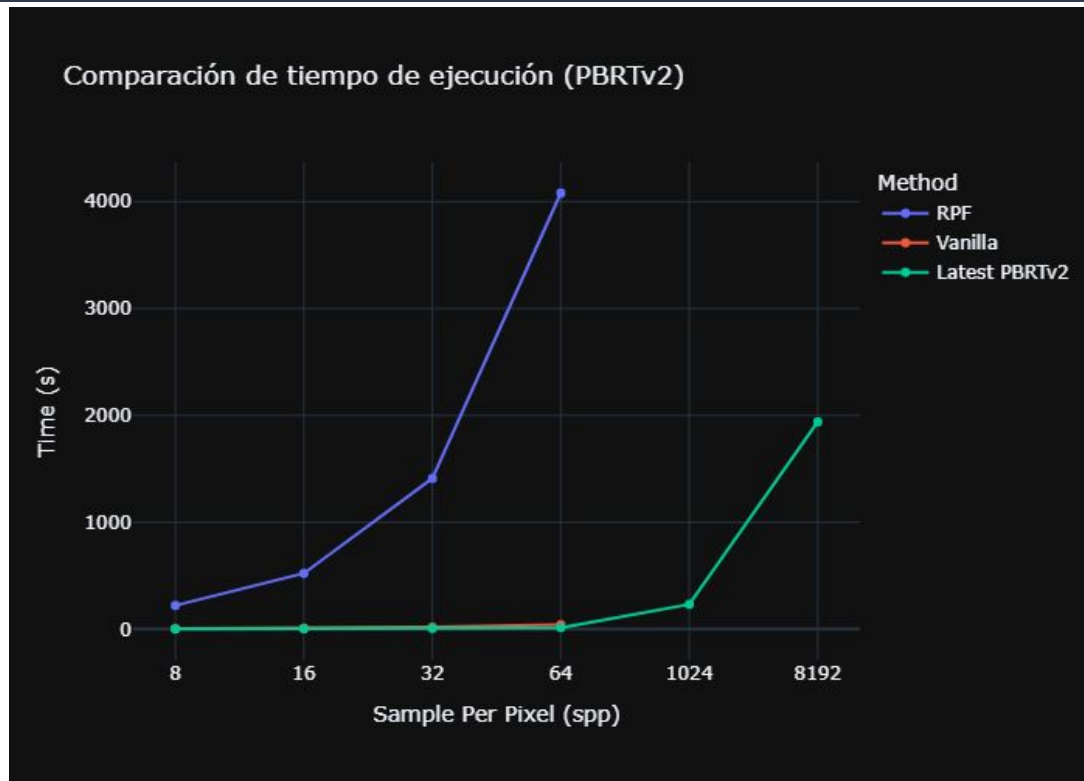
Referencia



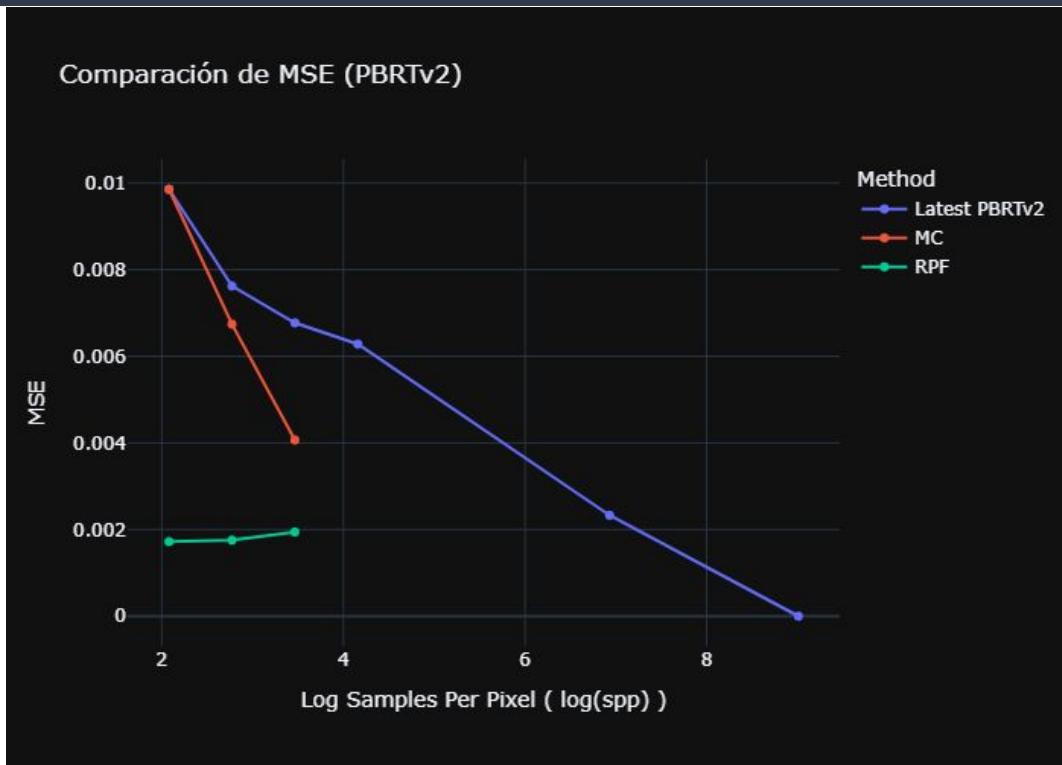
RPF



Experimentación: Tiempo




Experimentación: Mean Squared Error




Experimentación: Structural Similarity Index Measure




Resultados del Paper



(a) Input Monte Carlo (8 spp)



(b) Equal time MC (32 spp)



(e) Our approach (RPF)



(f) Reference Monte Carlo (8,192 spp)

Referencias

Sen, P., & Darabi, S. (2011). *Implementation of Random Parameter Filtering*. University of New Mexico.

Sen, P., & Darabi, S. (2012). On Filtering the Noise from the Random Parameters in Monte Carlo Rendering. *ACM Trans. Graph.*, 31(3), 18:1-18:15.